Projet Web Content : Analyse de Sentiments

CHAYMAE BOUHNAS

Mars 2025

Tâche 1(a) : Calcul des poids TF-IDF

La méthode TF-IDF (Term Frequency-Inverse Document Frequency) est une technique statistique utilisée pour évaluer l'importance d'un terme dans un document par rapport à un corpus. Elle repose sur deux composantes principales :

- **TF (Term Frequency)** : Mesure la fréquence d'un terme dans un document. La formule utilisée est $1 + \log_{10}(tf_{t,d})$, où $tf_{t,d}$ représente le nombre d'occurrences du terme t dans le document d.
- **IDF (Inverse Document Frequency)** : Mesure l'importance d'un terme dans l'ensemble du corpus. La formule est $\log_{10}\left(\frac{N}{df_t}\right)$, où N est le nombre total de documents et df_t est le nombre de documents contenant le terme t.

Le poids TF-IDF est obtenu en multipliant ces deux mesures : $\text{TF-IDF}(t, d) = \text{TF}(t, d) \times \text{IDF}(t)$.

Calcul des valeurs TF-IDF

Pour chaque terme du vocabulaire, les valeurs TF-IDF ont été calculées comme suit :

1. **Pour "plot"** :
   - Le terme apparaît dans les 4 documents (R1, R2, R3, R4).
   - $df = 4$, donc IDF $= \log_{10}(4/4) = \log_{10}(1) = 0$.
   - Le TF-IDF est donc nul pour tous les documents.
2. **Pour "predictable"** :
   - Le terme est présent dans R1 et R4.
   - $df = 2$, donc IDF $= \log_{10}(4/2) = \log_{10}(2) \approx 0.3010$.
   - R1 : $(1 + 0) \times 0.3010 = 0.3010$.
   - R4 : $(1 + 0) \times 0.3010 = 0.3010$.
3. **Pour "without"** :
   - Le terme n'apparaît que dans R1.
   - $df = 1$, donc IDF $= \log_{10}(4/1) = \log_{10}(4) \approx 0.6020$.
   - R1 : $(1 + 0) \times 0.6020 = 0.6020$.
4. **Pour "excitement"** :
   - Le terme est présent dans R1 et R3.
   - $df = 2$, donc IDF $= \log_{10}(4/2) = \log_{10}(2) \approx 0.3010$.
   - R1 : $(1 + 0) \times 0.3010 = 0.3010$.
   - R3 : $(1 + 0) \times 0.3010 = 0.3010$.
5. **Pour "won't"** :
   - Le terme n'apparaît que dans R1.
   - $df = 1$, donc IDF $= \log_{10}(4/1) = \log_{10}(4) \approx 0.6020$.

- R1 : $(1+0) \times 0.6020 = 0.6020$.

6. **Pour "recommend"** :
   - Le terme est présent dans R1 et R3.
   - $df = 2$, donc IDF $= \log_{10}(4/2) = \log_{10}(2) \approx 0.3010$.
   - R1 : $(1+0) \times 0.3010 = 0.3010$.
   - R3 : $(1+0) \times 0.3010 = 0.3010$.
7. **Pour "novel"** :
   - Le terme n'apparaît que dans R2.
   - $df = 1$, donc IDF $= \log_{10}(4/1) = \log_{10}(4) \approx 0.6020$.
   - R2 : $(1+0) \times 0.6020 = 0.6020$.
8. **Pour "story"** :
   - Le terme apparaît dans R2, R3 et R4.
   - $df = 3$, donc IDF $= \log_{10}(4/3) \approx 0.1249$.
   - R2 : $(1+0) \times 0.1249 = 0.1249$.
   - R3 : $(1+0) \times 0.1249 = 0.1249$.
   - R4 : $(1+0) \times 0.1249 = 0.1249$.
9. **Pour "interesting"** :
   - Le terme n'apparaît que dans R2.
   - $df = 1$, donc IDF $= \log_{10}(4/1) = \log_{10}(4) \approx 0.6020$.
   - R2 : $(1+0) \times 0.6020 = 0.6020$.
10. **Pour "fast-paced"** :
    - Le terme n'apparaît que dans R3.
    - $df = 1$, donc IDF $= \log_{10}(4/1) = \log_{10}(4) \approx 0.6020$.
    - R3 : $(1+0) \times 0.6020 = 0.6020$.
11. **Pour "filled"** :
    - Le terme n'apparaît que dans R3.
    - $df = 1$, donc IDF $= \log_{10}(4/1) = \log_{10}(4) \approx 0.6020$.
    - R3 : $(1+0) \times 0.6020 = 0.6020$.
12. **Pour "unconvincing"** :
    - Le terme n'apparaît que dans R4.
    - $df = 1$, donc IDF $= \log_{10}(4/1) = \log_{10}(4) \approx 0.6020$.
    - R4 : $(1+0) \times 0.6020 = 0.6020$.

Tableau des valeurs TF-IDF

Tâche 1(b) : Prédictions avec Régression Logistique

Le vecteur de poids utilisé pour la régression logistique est :

$$w = [0.5, -0.2, -0.3, 1.5, -0.3, 1.1, 0.9, 0.8, 1.3, 1.7, 0.1, -0.4]$$

Terme	R1	R2	R3	R4
plot	0.0000	0.0000	0.0000	0.0000
predictable	0.3010	0.0000	0.0000	0.3010
without	0.6020	0.0000	0.0000	0.0000
excitement	0.3010	0.0000	0.3010	0.0000
won't	0.6020	0.0000	0.0000	0.0000
recommend	0.3010	0.0000	0.3010	0.0000
novel	0.0000	0.6020	0.0000	0.0000
story	0.0000	0.1249	0.1249	0.1249
interesting	0.0000	0.6020	0.0000	0.0000
fast-paced	0.0000	0.0000	0.6020	0.0000
filled	0.0000	0.0000	0.6020	0.0000
unconvincing	0.0000	0.0000	0.0000	0.6020

Table 1: Tableau des valeurs TF-IDF

Calcul du score sigmoïde pour chaque avis

La fonction sigmoïde est utilisée pour transformer les scores en probabilités. Elle est définie par :

$$h(x|w) = \sigma(w \cdot x) = \frac{1}{1 + e^{-w \cdot x}}$$

où :

- $w \cdot x$ est le produit scalaire entre le vecteur de poids w et le vecteur TF-IDF x.
- x représente le document sous forme de vecteur.
- σ est la fonction sigmoïde, qui ramène les valeurs entre 0 et 1.

La classification est effectuée en utilisant un seuil de 0,5 :

- Si $h(x|w) > 0,5$, le sentiment est positif.
- Sinon, le sentiment est négatif.

Calculs pour chaque avis

1. **Pour R1** :

$$x = [0, 0.3010, 0.6020, 0.3010, 0.6020, 0.3010, 0, 0, 0, 0, 0]$$

$$\begin{aligned} w \cdot x = {} & 0.5 \times 0 + (-0.2) \times 0.3010 + (-0.3) \times 0.6020 \\ & + 1.5 \times 0.3010 + (-0.3) \times 0.6020 + 1.1 \times 0.3010 \\ & + 0.9 \times 0 + 0.8 \times 0 + 1.3 \times 0 + 1.7 \times 0 \\ & + 0.1 \times 0 + (-0.4) \times 0 \end{aligned}$$

$$w \cdot x = -0.0602 - 0.1806 + 0.4515 - 0.1806 + 0.3311 = 0.3612$$

$$\sigma(0.3612) = \frac{1}{1 + e^{-0.3612}} \approx 0.5896$$

Pour R2 :

$$x = [0, 0, 0, 0, 0, 0, 0.6020, 0.1249, 0.6020, 0, 0, 0]$$

$$w \cdot x = 0.9 \times 0.6020 + 0.8 \times 0.1249 + 1.3 \times 0.6020$$

$$w \cdot x = 0.5418 + 0.0999 + 0.7826 = 1.4243$$

$$\sigma(1.4243) = \frac{1}{1 + e^{-1.4243}} \approx 0.8060$$

Pour R3 :

$$x = [0, 0, 0, 0.3010, 0, 0.3010, 0, 0.1249, 0, 0.6020, 0.6020, 0]$$

$$w \cdot x = 1.5 \times 0.3010 + 1.1 \times 0.3010 + 0.8 \times 0.1249 + 1.7 \times 0.6020 + 0.1 \times 0.6020$$

$$w \cdot x = 0.4515 + 0.3311 + 0.0999 + 1.0234 + 0.0602 = 1.9661$$

$$\sigma(1.9661) = \frac{1}{1 + e^{-1.9661}} \approx 0.8770$$

Pour R4 :

$$x = [0, 0.3010, 0, 0, 0, 0, 0, 0.1249, 0, 0, 0, 0.6020]$$

$$w \cdot x = (-0.2) \times 0.3010 + 0.8 \times 0.1249 + (-0.4) \times 0.6020$$

$$w \cdot x = -0.0602 + 0.0999 - 0.2408 = -0.2011$$

$$\sigma(-0.2011) = \frac{1}{1 + e^{0.2011}} \approx 0.4500$$

Classification finale

- R1 : $0.5896 > 0.5 \rightarrow$ Positive
- R2 : $0.8060 > 0.5 \rightarrow$ Positive
- R3 : $0.8770 > 0.5 \rightarrow$ Positive
- R4 : $0.4500 < 0.5 \rightarrow$ Negative

Tâche 1(c) : Calcul de la Perte d'Entropie Croisée

La perte d'entropie croisée mesure l'écart entre la prédiction et la réalité. Elle est définie par :

$$L(y, \hat{y}) = -[y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})]$$

où :

- y est l'étiquette réelle (0 ou 1).
- $\hat{y}$ est la probabilité prédite (score sigmoïde).

Calcul pour chaque avis

Les étiquettes réelles sont $\{0, 1, 1, 0\}$ pour R1, R2, R3, R4.

1. **Pour R1** ($y = 0$, $\hat{y} = 0.5896$) :

$$L(0, 0.5896) = -(0 \times \log(0.5896) + (1 - 0) \times \log(1 - 0.5896))$$

$$L(0, 0.5896) = -(0 + \log(0.4104)) = -\log(0.4104) \approx 0.8893$$

2. **Pour R2** ($y = 1$, $\hat{y} = 0.8060$) :

$$L(1, 0.8060) = -(1 \times \log(0.8060) + (1 - 1) \times \log(1 - 0.8060))$$

$$L(1, 0.8060) = -\log(0.8060) \approx 0.2161$$

3. **Pour R3** ($y = 1$, $\hat{y} = 0.8770$) :

$$L(1, 0.8770) = -\log(0.8770) \approx 0.1311$$

4. **Pour R4** ($y = 0$, $\hat{y} = 0.4500$) :

$$L(0, 0.4500) = -\log(1 - 0.4500) = -\log(0.5500) \approx 0.5978$$

Perte d'entropie croisée moyenne

$$\text{Moyenne des pertes} = \frac{0.8893 + 0.2161 + 0.1311 + 0.5978}{4} \approx 0.4586$$

Tâche 1(d) : Prédiction pour une Nouvelle Critique

"The story is filled with excitement, I will recommend it."

Calcul TF-IDF pour le nouvel avis

Les termes présents sont : story, filled, excitement, recommend.

1. **Pour "story"** :
   - IDF déjà calculé : 0.1249.
   - TF-IDF = 0.1249.
2. **Pour "filled"** :
   - IDF déjà calculé : 0.6020.
   - TF-IDF = 0.6020.
3. **Pour "excitement"** :
   - IDF déjà calculé : 0.3010.
   - TF-IDF = 0.3010.
4. **Pour "recommend"** :
   - IDF déjà calculé : 0.3010.
   - TF-IDF = 0.3010.

Calcul du score sigmoïde

Le vecteur TF-IDF est :

$$x = [0, 0, 0, 0.3010, 0, 0.3010, 0, 0.1249, 0, 0, 0.6020, 0]$$

$$w \cdot x = 1.5 \times 0.3010 + 1.1 \times 0.3010 + 0.8 \times 0.1249 + 0.1 \times 0.6020$$

$$w \cdot x = 0.4515 + 0.3311 + 0.0999 + 0.0602 = 0.9427$$

$$\sigma(0.9427) = \frac{1}{1 + e^{-0.9427}} \approx 0.72$$

Puisque $0.72 > 0.5$, l'étiquette prédite est Positive.

Tâche 2 : Utilisation des Vecteurs Denses pour la Classification de Sentiments

Les vecteurs denses sont des représentations compactes de mots ou de documents dans un espace de dimension fixe. Contrairement à TF-IDF, qui repose sur des représentations creuses, les vecteurs denses capturent des relations sémantiques entre les termes. Ils sont souvent générés par des modèles comme word2vec ou GloVe.

Données utilisées

Quatre critiques représentées par des vecteurs denses de dimension 5 :

- R1 (critique 1) : $[0.58, -0.48, 0.65, -1.35, 1.85]$
- R2 (critique 2) : $[-0.61, 1.97, -1.06, 0.34, -0.37]$
- R3 (critique 3) : $[-1.46, 0.18, 0.07, 1.07, 1.74]$
- R4 (critique 4) : $[-1.64, -1.22, 1.98, -1.06, -1.04]$

(a) Processus de prédiction avec régression logistique

1. **Modèle mathématique** : On utilise la régression logistique avec la fonction sigmoïde $\sigma(z) = \frac{1}{1+e^{-z}}$.
2. **Vecteur de poids** : $w = [-0.3, 1.8, 0.9, 1.5, -0.1]$.
3. **Calcul du produit scalaire** pour chaque critique :

- **Pour R1** :

$$w \cdot d_1 = (-0.3)(0.58) + (1.8)(-0.48) + (0.9)(0.65) + (1.5)(-1.35) + (-0.1)(1.85)$$

$$w \cdot d_1 = -0.174 - 0.864 + 0.585 - 2.025 - 0.185 = -2.663$$

$$\sigma(-2.663) \approx 0.065 \rightarrow \textit{Negative}(\text{car } < 0.5)$$

- **Pour R2** :

$$w \cdot d_2 = (-0.3)(-0.61) + (1.8)(1.97) + (0.9)(-1.06) + (1.5)(0.34) + (-0.1)(-0.37)$$

$$w \cdot d_2 = 0.183 + 3.546 - 0.954 + 0.51 + 0.037 = 3.322$$

$$\sigma(3.322) \approx 0.964 \rightarrow \textit{Positive}(\text{car } > 0.5)$$

- **Pour R3** :

$$w \cdot d_3 = (-0.3)(-1.46) + (1.8)(0.18) + (0.9)(0.07) + (1.5)(1.07) + (-0.1)(1.74)$$

$$w \cdot d_3 = 0.438 + 0.324 + 0.063 + 1.605 - 0.174 = 2.256$$

$$\sigma(2.256) \approx 0.905 \rightarrow \textit{Positive}(\text{car } > 0.5)$$

- **Pour R4** :

$$w \cdot d_4 = (-0.3)(-1.64) + (1.8)(-1.22) + (0.9)(1.98) + (1.5)(-1.06) + (-0.1)(-1.04)$$

$$w \cdot d_4 = 0.492 - 2.196 + 1.782 - 1.59 + 0.104 = -1.408$$

$$\sigma(-1.408) \approx 0.196 \rightarrow \textit{Negative}(\text{car } < 0.5)$$

(b) Calcul de la perte d'entropie croisée

La perte d'entropie croisée est calculée comme suit :

$$L(y, p) = -\log(p) \quad \text{pour } y = 1 \quad \text{et} \quad L(y, p) = -\log(1 - p) \quad \text{pour } y = 0$$

où p est la probabilité prédite (score sigmoïde).
Les étiquettes réelles sont $\{0, 1, 1, 0\}$ pour R1, R2, R3, R4.

1. **Pour R1** ($y = 0$, $p = 0.065$) :

$$L = -\log(1 - 0.065) = -\log(0.935) \approx 0.067$$

2. **Pour R2** ($y = 1$, $p = 0.964$) :

$$L = -\log(0.964) \approx 0.037$$

3. **Pour R3** ($y = 1$, $p = 0.905$) :

$$L = -\log(0.905) \approx 0.100$$

4. **Pour R4** ($y = 0$, $p = 0.196$) :

$$L = -\log(1 - 0.196) = -\log(0.804) \approx 0.218$$

Perte moyenne

$$\text{Perte moyenne} = \frac{0.067 + 0.037 + 0.100 + 0.218}{4} \approx 0.106$$

(c) Prédiction pour un nouveau vecteur

Pour le nouveau vecteur $[0.52, 0.94, 0.75, -1.88, 1.61]$:

$$w \cdot d_{\text{new}} = (-0.3)(0.52) + (1.8)(0.94) + (0.9)(0.75) + (1.5)(-1.88) + (-0.1)(1.61)$$
$$w \cdot d_{\text{new}} = -0.156 + 1.692 + 0.675 - 2.82 - 0.161 = -0.77$$
$$\sigma(-0.77) \approx 0.316 \rightarrow \textit{Negative}(\text{car } < 0.5)$$

Tâche 3 : Comparaison entre TF-IDF et Vecteurs Denses

1. Nature de la représentation

- **TF-IDF** :
  - Représentation creuse (sparse) avec beaucoup de zéros.
  - Dimension égale à la taille du vocabulaire (potentiellement très grande).
  - Valeurs déterminées par la fréquence des termes et leur importance relative.
- **Vecteurs Denses** :
  - Représentation compacte avec peu de dimensions (ici 5).
  - Chaque dimension peut représenter des concepts abstraits plutôt que des mots spécifiques.
  - Valeurs continues distribuées uniformément.

2. Capture sémantique

- **TF-IDF** :
  - Capture uniquement la présence/absence et l'importance statistique des mots.
  - Ne capture pas les relations sémantiques (synonymes, antonymes, etc.).
  - Traite "bon" et "excellent" comme totalement différents.
- **Vecteurs Denses** :
  - Capture les relations sémantiques entre mots et concepts.
  - Des mots similaires ont des représentations proches dans l'espace vectoriel.
  - Permet de gérer la polysémie et les variations linguistiques.

3. Performance et efficacité

- **TF-IDF** :
  - Performance limitée par la variation lexicale (mots différents mais sens similaire).
  - Ne prend pas en compte la sémantique ni l'ordre des mots.
  - Sensible aux fautes d'orthographe et aux différentes formes d'un même mot.
  - Représentation creuse (sparse) qui peut être inefficace pour de grands corpus.
  - Difficulté à capturer les relations contextuelles entre les termes.
- **Vecteurs Denses** :
  - Meilleure performance pour la détection de similarité sémantique.
  - Représentation compacte et efficace, même pour de grands corpus.
  - Robustesse face aux variations linguistiques et aux fautes d'orthographe.
  - Permet des opérations mathématiques significatives (addition, soustraction de concepts).
  - Nécessite plus de ressources pour l'entraînement initial des modèles.